

智能控制—迭代学习控制

朱芳来

第一章 绪论

1.1 迭代学习控制技术及其发展概况

- 从根本上来看，控制器的设计问题可以归为两大类：调节问题和跟踪问题，而调节问题也可以看成是跟踪问题的特殊情况。
- 迭代学习控制的一个主要任务就是，实现被控系统的输出零误差地跟踪期望轨迹。
- 研究具有学习能力的控制器，以达到对期望轨迹的跟踪，一直是控制工程师们探索的问题。

- 迭代学习控制的概念最早（1978年）由日本学者Uchiyama在一篇有关机器人控制的论文提出，但因为文章是以日文发表的，所以但是并没有引起人们的注意。
- 1984年，另一个日本人Arimoto及其合作者们将Uchiyama的思想加以完善，建立了实用的算法，并提出了更为正规的迭代学习理论，并以英文发表了其研究成果，从而使迭代学习控制成为引人注目的课题。

- 迭代学习控制是智能系统中具有严格数学描述的一个分支，特别适用于具有重复性质的控制对象，它的目标是实现有限区间上的完全跟踪任务。

1.2 迭代学习控制的研究内容及其基本原理

迭代学习控制的主要研究内容包括：学习算法的稳定性与收敛性、学习速度、学习律及对学习系统结构的研究、学习过程的鲁棒性等。

迭代学习控制的基本原理

设被控对象的动态过程为

$$\begin{cases} \dot{x} = f(t, x, u) \\ y = g(t, x, u) \end{cases} \quad (1.1)$$

其中 $x \in \mathbf{R}^n$, $y \in \mathbf{R}^m$, $u \in \mathbf{R}^r$ 而 f, g 为相应维数的向量函数。要求系统在时间 $t \in [0, T]$ 内的输出 $y(t)$ 跟踪期望输出 $y_d(t)$ 。假定期望输出 $u_d(t)$ 存在, 即: 在给定的初始状态 $x(0)$ 下 $u_d(t)$ 是式(1.1)当 $y(t)=y_d(t)$ 的解存在, 则迭代学习控制的目标就是通过多次重复的运行, 在一定的学习律下 $u(t) \rightarrow u_d(t)$, $y(t) \rightarrow y_d(t)$.

在第k次运行时(1.1)表示为

$$\begin{cases} \dot{x}_k = f(t, x_k, u_k) \\ y_k = g(t, x_k, u_k) \end{cases} \quad (1.2)$$

输出误差为

$$e_k(t) = y_d(t) - y_k(t) \quad (1.3)$$

其中下表表示第k次迭代。

迭代学习控制分为开环学习和闭环学习。开环学习控制的方法是：第k+1次的控制等于第k次控制再加上第k次输出误差的**PID**校正项，即

$$u_{k+1}(t) = u_k(t) + \Gamma_p e_k(t) + \Gamma_i \int_0^t e_k(s) ds + \Gamma_d \frac{de_k(t)}{dt} \quad (1.4)$$

其中 $\Gamma_p, \Gamma_i, \Gamma_d$ 分别为**PID**学习增益矩阵。更一般的开环学习律可以写成

$$u_{k+1}(t) = L(u_k(t), e_k(t)) \quad (1.5)$$

这里**L**是线性或非线性算子。

开环**PID**学习控制的基本结构如图1.1所示

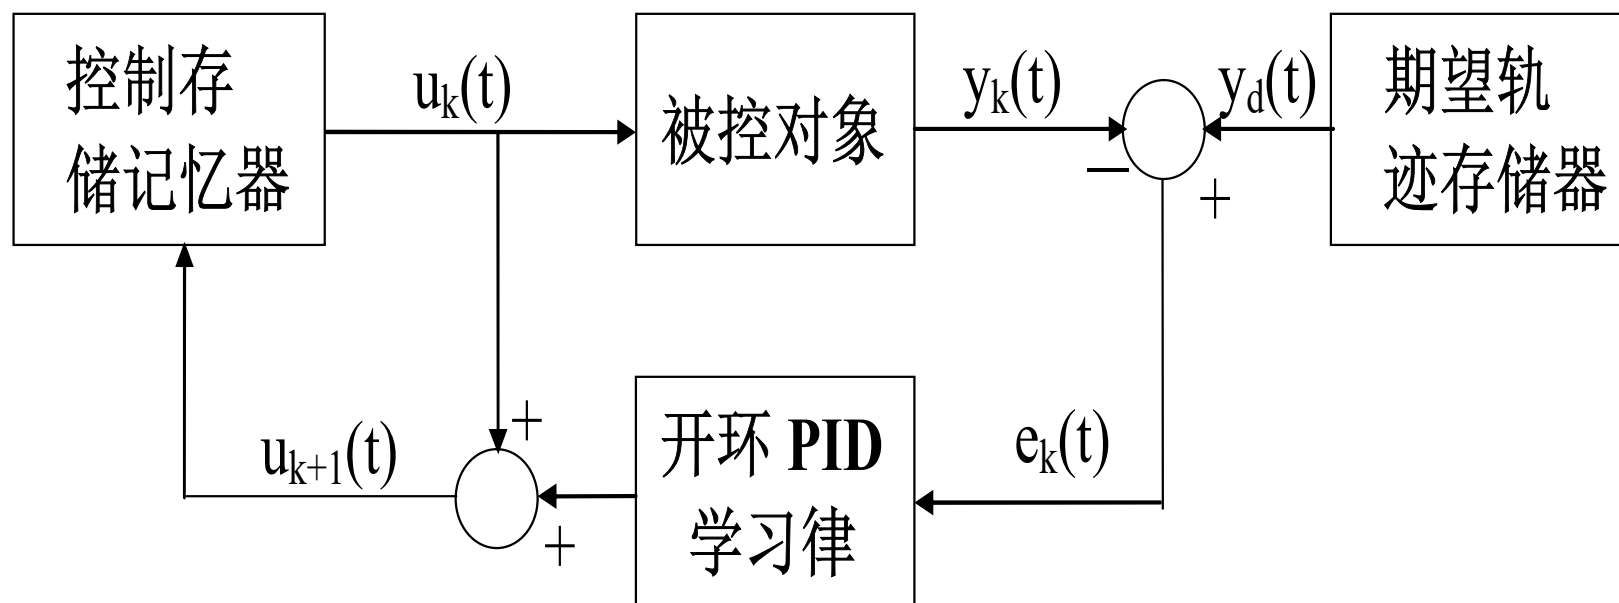


图1.1 开环PID学习控制的基本结构

闭环**PID**学习控制策略是取第**k+1**次运行的误差作为学习的修正项，即

$$u_{k+1}(t) = u_k(t) + \Gamma_p e_{k+1}(t) + \Gamma_i \int_0^t e_{k+1}(s) ds + \Gamma_d \frac{de_{k+1}(t)}{dt} \quad (1.6)$$

更一般的闭环学习律

$$u_{k+1}(t) = L(u_k(t), e_{k+1}(t)) \quad (1.7)$$

其中**L**是线性或非线性算子。

闭环**PID**学习控制的基本结构如图**1.2**所示

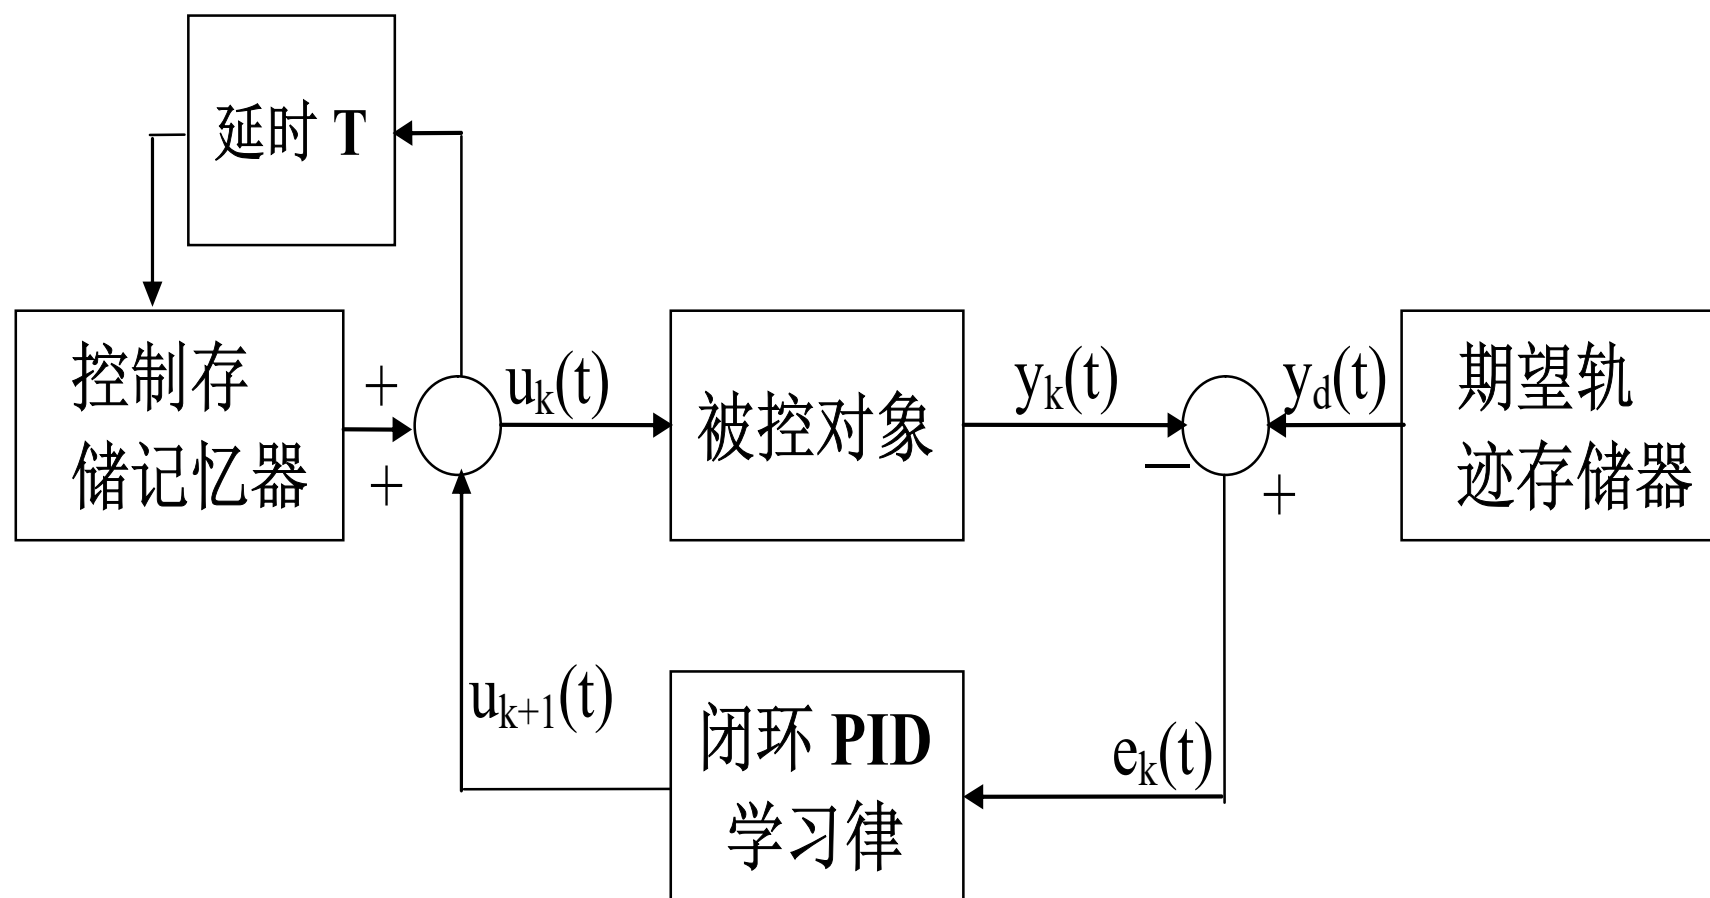


图1.2 闭环PID迭代学习控制基本结构

第二章 数学基础

2.1 一些基本概念

定义2.1： 设 X 为一个集合，若在该集合上定义两种运算，一个称为加法，记为“+”；一个称为数量乘法，记为“ \cdot ”。加法和数量乘法的结果皆为 X 中的元素，且它们满足：

1) $\forall x, y \in X, x + y = y + x$

2) $\forall x, y, z \in X, (x + y) + z = x + (y + x)$

3) 存在 X 中一个元素，称为零元，记为 0 ，使得

使得 $\forall x \in X$ ，有

$$x+0=0+x=x$$

4) $\forall x \in X$ ，存在 X 中的一个元素，称为 x 的负元，记为 $-x$ ，使得

$$x+(-x)=0$$

5) 对任意的两个数 $a, b, \forall x \in X$ ，有

$$(a \cdot b) \cdot x = a \cdot (b \cdot x)$$

6) 对任意的两个数 $a, b, \forall x \in X$ ，有

$$(a + b) \cdot x = a \cdot x + b \cdot x$$

7) 对任意的数 \mathbf{a} , $\forall x, y \in X$, 有

$$a \cdot (x + y) = a \cdot x + a \cdot y$$

8) $\forall x \in X$, $1 \cdot x = x$

则称 \mathbf{X} 为线性空间, 或向量空间。

例2.1 设 $\mathbf{C[a,b]}$ 表示区间 $[\mathbf{a},\mathbf{b}]$ 上所有连续函数构成的集合, 若按通常函数的加法及数与函数的乘法, 则 $\mathbf{C[a,b]}$ 构成了一个线性空间。同样, 对 \mathbf{n} -维实数向量全体所组成的集合 $\mathbf{R^n}$,按通常向量的加法及数与向量的乘法, 构成了一个线性空间。

定义2.2 设 X 是一个线性空间, $\|\cdot\|$ 为从 X 到 $[0, +\infty)$ 的一个映射, 且满足:

$$1) \forall a \in \mathbf{R}, \forall x \in X, \|a \cdot x\| = |a| \cdot \|x\|$$

$$2) \forall x, y \in X, \|x + y\| \leq \|x\| + \|y\|$$

$$3) \|x\| = 0 \Leftrightarrow x = 0$$

则成映射 $\|\cdot\|$ 为线性空间 X 上的一个范数, 配有范数的线性空间称为赋范空间。

例2.2 对连续函数空间 $C[a, b]$, $\forall f \in C[a, b]$, 定义

$$\|f\| = \max_{a \leq t \leq b} |f(t)|$$

则容易验证, 上式定义的确实是一个 $C[a, b]$ 上的范数。

例2.3 对向量空间 \mathbf{R}^n , $\forall x = [x_1 \ x_2 \ \cdots \ x_n]^T \in \mathbf{R}^n$

可以定义如下的一些范数:

1) p范数(Holder范数):

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$

2) ∞ -范数: $\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|$

3) 1-范数: $\|x\|_1 = \sum_{i=1}^n |x_i|$

4) 2-范数(Euclid):

$$\|x\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2} = \sqrt{x^T x}$$

定义2.3 设 X 是赋范空间, $\{x_n\}_{n \geq 1}$ 为 X 中的一个序列, x 为 X 中的一个元素, 若 $\lim_{n \rightarrow \infty} \|x_n - x\| = 0$ 则称序列 $\{x_n\}_{n \geq 1}$ 在 X 中按范数收敛到 x , 简称 $\{x_n\}_{n \geq 1}$ 收敛到 x , 记为 $\lim_{n \rightarrow \infty} x_n = x$ 或 $x_n \rightarrow x \quad n \rightarrow \infty$

定义2.4 设 X, Y 是赋范空间, 从 X 到 Y 的一个映射 S 称为从 X 到 Y 的算子, 记为 $S: X \rightarrow Y$.

例如, 函数

$$f(x) = \begin{bmatrix} x_1 x_2^2 \\ x_1 + x_2^3 \\ x_2 \end{bmatrix}$$

其中 $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \mathbf{R}^2$

可以看成从线性空间 \mathbf{R}^2 到线性空间 \mathbf{R}^3 的一个映射，因而， \mathbf{f} 定义了从线性空间 \mathbf{R}^2 到线性空间 \mathbf{R}^3 的一个算子。

第三章 迭代学习控制的主要结论

3.1 开环P型学习

设被控系统的动态过程为

$$\begin{cases} \dot{x}(t) = f(t, x(t), u(t)) \\ y(t) = g(t, x(t)) + D(t)u(t) \end{cases} \quad (3.1)$$

其中 $x \in \mathbf{R}^n$, $y \in \mathbf{R}^m$, $u \in \mathbf{R}^r$ 分别为系统的状态, 可测输出和控制输入。要求在时间 $t \in [t_0, T]$ 内系统的输出精确地跟踪期望输出 $y_d(t)$ 。

在第k次运行时，迭代学习的动态方程是：

$$\begin{cases} \dot{x}_k(t) = f(t, x_k(t), u_k(t)) \\ y_k(t) = g(t, x_k(t)) + D(t)u_k(t) \end{cases} \quad (3.2)$$

输出误差为

$$e_k(t) = y_d(t) - y_k(t) \quad (3.3)$$

开环P型学习律为

$$u_{k+1}(t) = u_k(t) + \Gamma(t)e_k(t) \quad (3.4)$$

其中 $\Gamma(t)$ 为学习增益。令

$$\begin{cases} \delta x_k(t) = x_d(t) - x_k(t) \\ \delta y_k(t) = y_d(t) - y_k(t) \\ \delta u_k(t) = u_d(t) - u_k(t) \end{cases} \quad (3.5)$$

其中 \mathbf{x}_d , \mathbf{y}_d , \mathbf{u}_d 分别为期望轨迹上的状态, 输出和控制。

如下的定理给出了迭代学习控制算法的收敛性。

定理3.1: 设被控系统的动态方程如(3.1)所示, 且在 $t \in [0, T]$ 中满足下面的条件:

(A1) $\forall t, u, x_1, x_2$ 有

$$\|f(t, x_1, u) - f(t, x_2, u)\| \leq F(t, u) \cdot \|x_1 - x_2\|$$

(A2) $\forall t, x, u_1, u_2$ 有

$$\|f(t, x, u_1) - f(t, x, u_2)\| \leq M \cdot \|u_1 - u_2\|$$

(A3) $\forall t, x_1, x_2$ 有

$$\|g(t, x_1) - g(t, x_2)\| \leq M \|x_1 - x_2\|$$

(A4) 每次运行时的初始误差 $\{\delta x_k(0)\}_{k \geq 0}$ 为一收敛到零的序列。

(A5) 存在唯一的控制 $u_d(t)$ 使得系统的状态和系统的期望输出值分别为 $x_d(t)$ 和 $y_d(t)$

则迭代学习律(3.4)收敛的充分必要条件是谱半径

$$\rho[I - \Gamma(t)D(t)] < 1, t \in [0, T]$$

3.2 开环D型学习

设被控系统的动态方程为

$$\begin{cases} \dot{x}(t) = f(t, x(t)) + B(t)u(t) \\ y(t) = C(t)x(t) \end{cases}$$

其中**f**的结构与参数**B**, **C**均为未知。

要求在 $t \in [0, T]$ 内系统的输出 $y(t)$ 能精确地跟踪期望输出 $y_d(t)$ ，在 k 次运行时，系统的动态方程为

$$\begin{cases} \dot{x}_k(t) = f(t, x_k(t)) + B(t)u_k(t) \\ y_k(t) = C(t)x_k(t) \end{cases}$$

输出误差为

$$e_k(t) = y_d(t) - y_k(t)$$

开环D型学习律为

$$u_{k+1}(t) = u_k(t) + \Gamma(t)\dot{e}_k(t)$$

3.3 闭环P型学习和闭环D型学习

考虑被控系统(3.1)，则闭环P型和闭环D型学习律分别为

$$u_{k+1}(t) = u_k(t) + \Gamma(t)e_{k+1}(t)$$

$$u_{k+1}(t) = u_k(t) + \Gamma(t)\dot{e}_{k+1}(t)$$

例：设被控系统为

$$\begin{cases} \begin{bmatrix} \dot{x}_1(t) \\ \dot{x}_2(t) \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -(2+5t) & -(3+2t) \end{bmatrix} \begin{bmatrix} x_1(t) \\ x_2(t) \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} u(t) \\ y(t) = \begin{bmatrix} 0 & 1 \end{bmatrix} \begin{bmatrix} x_1(t) \\ x_2(t) \end{bmatrix} \end{cases}$$

要求在 $[0, 1]$ 时间内跟踪期望输出 $y_d(t)=12t^2(1-t)$,
用开环**D**型学习算法，给出算法。

开环**D**型学习律为

$$u_{k+1}(t) = u_k(t) + \Gamma \dot{e}_k(t) \quad (3.5)$$

$$\text{其中 } e_k(t) = y_d(t) - y_k(t) \quad (3.6)$$

原系统展开为

$$\begin{cases} \dot{x}_1 = x_2 \\ \dot{x}_2 = -(2+5t)x_1 - (3+2t)x_2 + u \end{cases} \quad (3.7)$$

$$y = x_2$$

于是，期望输出等价于

$$y_d = x_{2d} = 12t^2 - 12t^3$$

代入(3.7)得到

$$\dot{x}_{1d} = x_{2d} = 12t^2 - 12t^3$$

既有

$$x_{1d} = 4t^3 - 3t^4 + c$$

于是，期望状态为

$$x_d = \begin{bmatrix} x_{1d} \\ x_{2d} \end{bmatrix} = \begin{bmatrix} 4t^3 - 3t^4 + c \\ 12t^2 - 12t^3 \end{bmatrix}$$

如果取初始状态为

$$x_0 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

则期望状态具体为

$$x_d = \begin{bmatrix} x_{1d} \\ x_{2d} \end{bmatrix} = \begin{bmatrix} 4t^3 - 3t^4 \\ 12t^2 - 12t^3 \end{bmatrix}$$

由(3.6)知,

$$\begin{aligned} \dot{e}_k &= \dot{y}_d - \dot{y}_k = 24t - 36t^2 - \dot{x}_{2k} \\ &= 24t - 36t^2 + (2 + 5t)x_{1k} + (3 + 2t)x_{2k} + u_k \end{aligned}$$

将上式代入(3.5), 并整理得

$$u_{k+1} = (1 - \Gamma)u_k + \Gamma(24t - 36t^2 + [2 + 5t \quad 3 + 2t] \begin{bmatrix} x_{1k} \\ x_{2k} \end{bmatrix})$$

由此整理出算法，令

$$A(t) = \begin{bmatrix} 0 & 1 \\ -(2+5t) & -(3+2t) \end{bmatrix}, B = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, C = [0 \quad 1]$$

则第k步状态方程为

$$\dot{x}_k(t) = A(t)x_k(t) + Bu_k(t)$$

开始步(第0步)，初始状态和初始控制分别为

$$x_0(0) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, u_0(t) = 0$$

第 $k(k \geq 1)$ 步，初始状态取为

$$x_k(0) = \begin{bmatrix} 1 + \frac{1}{k} \\ \frac{1}{k} \end{bmatrix}$$

而迭代学习控制由()给出，学习算法收敛的充分性条件是 $0 < \Gamma < 2$ ，如可以取 $\Gamma = 0.7$




图1 第3步迭代学习




图2 第5步迭代学习




图3 第7步迭代学习

3.4 微分方程数值解仿真方法

考虑微分方程

$$\dot{x}(t) = f(t, x(t)) \quad (3.8)$$

其中 $x(t) \in \mathbf{R}^n, t \in \mathbf{R}^+$

- 微分方程的解析解：对微分方程(3.8)，给定在初始时刻 t_0 的初始条件 $x(t_0)=x_0$ ，如果它的解存在且可以用一个明确的数学表达式表示：

$$x(t) = \phi(t; t_0, x_0) \quad (3.9)$$

其中(3.9)满足 $\phi(t_0; t_0, x_0) = x_0$ 且 $\dot{\phi}(t; t_0, x_0) = f(t, \phi(t; t_0, x_0))$

则称(3.9)是微分方程(3.8)的解析解。

- 微分方程的数值解：给定解的时间区间 $[a,b]$ ，对时间区间插入若干个点 t_0, t_1, \dots, t_n ，既有

$$a=t_0 < t_1 < \dots < t_n = b$$

如果能够得到在这些时间点上微分方程(3.8)的解的近似值 x_1, x_2, \dots, x_n ，则如下的表格

t_0	t_1	\dots	t_n
x_1	x_2	\dots	x_n

称为微分方程(3.8)的数值解。

- 微分方程数值解方法：龙格-库达方法

% %

```
function [t,x]=myode45(f,a,b,h,x0)
```

```
t=a:h:b;
```

```
n1=size(t);
```

```
n=n1(2);
```

```
x(:,1)=x0;
```

```
for i=1:n
```

```
    tt=a+(i-1)*h;
```

```
    K1=feval(f,tt,x(:,i));
```

```
    K2=feval(f,tt+h/2,x(:,i)+(h/2)*K1);
```

```
    K3=feval(f,tt+h/2,x(:,i)+(h/2)*K2);
```

```
    K4=feval(f,tt+h,x(:,i)+h*K3);
```

```
    x(:,i+1)=x(:,i)+(h/6)*(K1+2*K2+2*K3+K4);
```

```
end
```

```
x=x(:,1:n);
```

% %